

# Capítulo II: Variáveis Aleatórias Reais

Probabilidades e Aplicações  
Licenciatura em Ciências da Computação  
Universidade do Minho  
Ano Letivo 2023/2024

# 1. Definição e Exemplos. Considerações gerais.

É frequente estarmos interessados em associar aos resultados de uma experiência aleatória uma, ou mais, características numéricas.

Por exemplo, para a experiência aleatória que consiste em efetuar dois lançamentos consecutivos de um dado, podemos estar interessados em estudar:

- o número de faces par obtidas;
- a soma das faces obtidas;
- a diferença, em valor absoluto, entre as faces obtidas;
- etc...

# 1. Definição e Exemplos. Considerações gerais.

Se estivermos interessados em apenas uma característica numérica, matematicamente tal é formalizado através de uma função que a cada elemento do espaço amostral,  $\omega \in \Omega$ , faz corresponder um número real, i.e., uma função

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega &\rightarrow X(\omega) \end{aligned}$$

em que  $\Omega$  é o espaço amostral da experiência aleatória.

# 1. Definição e Exemplos. Considerações gerais.

## Exemplo:

Suponhamos que estamos interessados em estudar o número de faces par obtidas nos dois lançamentos consecutivos do dado. Neste caso,

$$\Omega = \{(x_1, x_2) : x_i \in \{1, 2, 3, 4, 5, 6\}, i \in \{1, 2\}\}$$

e a função  $X$  é dada por

$$\begin{aligned} X((1, 1)) &= X((1, 3)) = X((1, 5)) = X((3, 1)) = X((3, 3)) = X((3, 5)) = \\ &= X((5, 1)) = X((5, 3)) = X((5, 5)) = 0, \end{aligned}$$

$$\begin{aligned} X((2, 2)) &= X((2, 4)) = X((2, 6)) = X((4, 2)) = X((4, 4)) = X((4, 6)) = \\ &= X((6, 2)) = X((6, 4)) = X((6, 6)) = 2 \end{aligned}$$

e  $X(\omega) = 1$  para os restantes elementos de  $\Omega$ .

# 1. Definição e Exemplos. Considerações gerais.

Se quisermos estudar, em simultâneo,  $k$  características numéricas, com  $k \in \mathbb{N}$ , somos conduzidos a uma função vectorial

$$\begin{aligned} \mathbf{X}: \Omega &\rightarrow \mathbb{R}^k \\ \omega &\rightarrow (X_1(\omega), X_2(\omega), \dots, X_k(\omega)). \end{aligned}$$

Neste capítulo vamos estudar apenas o caso unidimensional ( $k = 1$ ).

# 1. Definição e Exemplos. Considerações gerais.

**Os acontecimentos**, cujas probabilidades nos interessa calcular, são agora **expressos através de subconjuntos reais** que são elementos de  $\mathcal{B}(\mathbb{R})$ .

No exemplo anterior, o acontecimento “não saiu qualquer face par” é dado por:

$$\begin{aligned} X^{-1}(\{0\}) &= \{\omega \in \Omega : X(\omega) = 0\} \\ &= \{(1, 1), (1, 3), (1, 5), (3, 1), (3, 3), (3, 5), (5, 1), (5, 3), (5, 5)\}. \end{aligned}$$

O acontecimento “saiu pelo menos uma face par” corresponde a

$$\begin{aligned} X^{-1}(\{1, 2\}) &= \{\omega \in \Omega : X(\omega) \in \{1, 2\}\} \\ &= \{(1, 2), (1, 4), (1, 6), (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \\ &\quad (3, 2), (3, 4), (3, 6), (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \\ &\quad (5, 2), (5, 4), (5, 6), (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6)\}. \end{aligned}$$

# 1. Definição e Exemplos. Considerações gerais.

Para simplificar a notação, os acontecimentos anteriores podem ser abreviados por “ $X = 0$ ” e “ $X \in \{1, 2\}$ ”, respetivamente, i.e.,

$$X^{-1}(\{0\}) \equiv (X = 0)$$

e

$$X^{-1}(\{1, 2\}) \equiv (X \in \{1, 2\})$$

Observe que na descrição destes dois acontecimentos foram usados subconjuntos reais que são elementos de  $\mathcal{B}(\mathbb{R})$ , nomeadamente:

- $\{0\}$  no primeiro caso;
- $\{1, 2\}$  no segundo caso.

# 1. Definição e Exemplos. Considerações gerais.

De um modo geral, estaremos interessados em calcular probabilidades de acontecimentos da forma

$$X^{-1}(E) = \{\omega \in \Omega : X(\omega) \in E\} \equiv (X \in E),$$

em que  $E$  é um subconjunto real elemento de  $\mathcal{B}(\mathbb{R})$ .

Observe que é preciso garantir que estes acontecimentos pertencem a  $\mathcal{A}$ , a  $\sigma$ -álgebra sobre o espaço amostral  $\Omega$ , de modo a que a sua probabilidade esteja bem definida.

Assim, sendo  $(\Omega, \mathcal{A}, P)$  o espaço de probabilidade da experiência, a função  $X$  deverá ser tal que

$$\forall E \in \mathcal{B}(\mathbb{R}), X^{-1}(E) \in \mathcal{A},$$

de modo a que

$$P(X \in E) \equiv P(X^{-1}(E)) = P(\{\omega \in \Omega : X(\omega) \in E\})$$

esteja definida para todo o  $E \in \mathcal{B}(\mathbb{R})$ .



# 1. Definição e Exemplos. Considerações gerais.

## Definição

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma função.  $X$  diz-se uma variável aleatória real (v.a.r.) se

$$\forall E \in \mathcal{B}(\mathbb{R}), X^{-1}(E) \in \mathcal{A}.$$

É difícil provar, usando a definição, que uma certa função é uma v.a.r.. Na prática, usaremos resultados mais simples para verificar se uma certa função é ou não uma v.a.r.. Em particular, o teorema seguinte será muito útil.

## Teorema

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma função.  $X$  é v.a.r. sse

$$\forall c \in \mathbb{R}, X^{-1}([-\infty, c]) \in \mathcal{A}.$$

[Demonstração] [Ver Lopes e Gonçalves, 2000]

# 1. Definição e Exemplos. Considerações gerais.

Exemplos: **1)** Considere a experiência aleatória que consiste em lançar uma moeda equilibrada. O espaço de probabilidade é  $(\Omega, \mathcal{P}(\Omega), P)$ , em que  $\Omega = \{cara, coroa\}$  e  $P$  é a medida de Laplace. Usando o teorema anterior, vamos provar que a função  $X : \Omega \rightarrow \mathbb{R}$  definida por  $X(cara) = 1$  e  $X(coroa) = 0$  é uma v.a.r..

Seja  $c \in \mathbb{R}$  qualquer. Tem-se,

$$X^{-1}(] - \infty, c]) = \begin{cases} \emptyset & \text{se } c < 0 \\ \{coroa\} & \text{se } 0 \leq c < 1 \\ \Omega & \text{se } c \geq 1 \end{cases}.$$

Uma vez que  $\emptyset \in \mathcal{P}(\Omega)$ ,  $\{coroa\} \in \mathcal{P}(\Omega)$  e  $\Omega \in \mathcal{P}(\Omega)$ , podemos afirmar que, qualquer que seja  $c \in \mathbb{R}$ ,  $X^{-1}(] - \infty, c]) \in \mathcal{P}(\Omega)$ , ficando assim provado que  $X$  é uma v.a.r..

Observe que o acontecimento “saiu uma cara” corresponde a  $X^{-1}(\{1\})$  (ou simplesmente “ $X = 1$ ”) e a sua probabilidade é

$$P(X = 1) \equiv P(X^{-1}(\{1\})) = P(\{cara\}) = \frac{1}{2}.$$

# 1. Definição e Exemplos. Considerações gerais.

Exemplos: **2)** Sejam  $(\Omega, \mathcal{A}, P)$  o espaço de probabilidade associado a uma certa experiência aleatória e  $B$  um acontecimento (i.e.,  $B \in \mathcal{A}$ ).

Vamos provar que a função indicatriz do conjunto  $B$ , i.e., a função  $\mathbf{1}_B : \Omega \rightarrow \mathbb{R}$  definida por  $\mathbf{1}_B(\omega) = 1$ , se  $\omega \in B$ , e  $\mathbf{1}_B(\omega) = 0$ , se  $\omega \in \bar{B}$ , é uma v.a.r..

Seja  $c \in \mathbb{R}$  qualquer. Tem-se,

$$\mathbf{1}_B^{-1}(] - \infty, c]) = \begin{cases} \emptyset & \text{se } c < 0 \\ \bar{B} & \text{se } 0 \leq c < 1 \\ \Omega & \text{se } c \geq 1 \end{cases}.$$

Uma vez que  $\emptyset \in \mathcal{A}$ ,  $\bar{B} \in \mathcal{A}$  (porque  $B \in \mathcal{A}$ ) e  $\Omega \in \mathcal{A}$ , podemos concluir que, qualquer que seja  $c \in \mathbb{R}$ ,  $\mathbf{1}_B^{-1}(] - \infty, c]) \in \mathcal{A}$ , e fica assim provado que  $\mathbf{1}_B$  é uma v.a.r..

O acontecimento “ $\mathbf{1}_B = 0$ ” corresponde a “não se obteve um elemento do conjunto  $B$  na realização da experiência aleatória” e tem-se

$$P(\mathbf{1}_B = 0) \equiv P\left(\mathbf{1}_B^{-1}(\{0\})\right) = P(\bar{B}) = 1 - P(B).$$

# 1. Definição e Exemplos. Considerações gerais.

## Definição

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r.. Chamamos  $\sigma$ -álgebra gerada por  $X$  à seguinte família de subconjuntos de  $\Omega$

$$X^{-1}(\mathcal{B}(\mathbb{R})) = \{X^{-1}(B), B \in \mathcal{B}(\mathbb{R})\}.$$

Note que, pela definição de v.a.r., tem-se obviamente

$$X^{-1}(\mathcal{B}(\mathbb{R})) \subseteq \mathcal{A}.$$

# 1. Definição e Exemplos. Considerações gerais.

Na prática, muitas vezes temos que lidar com uma função de uma v.a.r.. A questão que se coloca é em que condições é que a composição de uma função, real de variável real, com uma v.a.r. resulta ainda numa v.a.r..

## Teorema

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$ . Se  $\phi$  é uma função contínua então  $\phi(X)$  também é uma v.a.r..

[Demonstração] [ver Lopes e Gonçalves, 2000]

Exemplos: Se  $X$  é uma v.a.r. então

- $X^2$  é uma v.a.r. (de uma forma geral,  $X^k, k \in \mathbb{N}$ , é uma v.a.r.);
- $e^X$  é uma v.a.r.;
- $|X|$  é uma v.a.r.;
- se  $X > 0$ ,  $\log(X)$  é uma v.a.r..

## 2. Lei de probabilidade e função de distribuição.

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r..  
Tem-se o seguinte diagrama:

$$\begin{array}{ccccc} \Omega & & \xrightarrow{X} & & \mathbb{R} \\ & & & & \\ [0,1] & \xleftarrow{P} & X^{-1}(\mathcal{B}(\mathbb{R})) & \xleftarrow{X^{-1}} & \mathcal{B}(\mathbb{R}) \end{array}$$

### Definição

A função  $P_X : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1]$  definida por  $P_X = P \circ X^{-1}$ , ie,

$$P_X(B) = P(X^{-1}(B)) \equiv P(X \in B), \quad B \in \mathcal{B}(\mathbb{R}),$$

é designada de *lei de probabilidade* da v.a.r.  $X$ .

Observação:  $P_X$  é uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  [ver Folhas Práticas para demonstração].

## 2. Lei de probabilidade e função de distribuição.

### Definição

A função  $F_X : \mathbb{R} \rightarrow [0, 1]$  definida por: para  $c \in \mathbb{R}$ ,

$$F_X(c) = P_X([-\infty, c]) = P(X^{-1}([-\infty, c])) \equiv P(X \in [-\infty, c]) \equiv P(X \leq c),$$

é designada de *função de distribuição* da v.a.r.  $X$  ou *função de distribuição da lei de probabilidade*  $P_X$ .

### Observação: [V. IMP.]

Uma vez que  $\pi(\mathbb{R}) = \{[-\infty, c], c \in \mathbb{R}\}$  é um  $\pi$ -sistema sobre  $\mathbb{R}$  e é tal que  $\sigma(\pi(\mathbb{R})) = \mathcal{B}(\mathbb{R})$ , a lei de probabilidade  $P_X$  fica caracterizada pela respectiva função de distribuição  $F_X$  (recorde o Lema enunciado no final do Capítulo I). Assim, se uma outra v.a.r.  $Y$  tiver a mesma função de distribuição que  $X$  (i.e., se  $F_X = F_Y$ ), então a lei de probabilidade de  $Y$  coincide com a lei de probabilidade de  $X$ , ou seja, tem-se

$$\forall B \in \mathcal{B}(\mathbb{R}), P_X(B) = P_Y(B).$$

## 2. Lei de probabilidade e função de distribuição.

Exemplo: Voltemos à experiência que consiste em lançar uma moeda equilibrada. O espaço de probabilidade é  $(\Omega, \mathcal{P}(\Omega), P)$ , em que  $\Omega = \{cara, coroa\}$  e  $P$  é a medida de Laplace.

A função de distribuição da v.a.r.  $X : \Omega \rightarrow \mathbb{R}$ , definida por  $X(cara) = 1$  e  $X(coroa) = 0$ , é dada por

$$\begin{aligned} c \in \mathbb{R}, F_X(c) &= P(X \leq c) \equiv P\left(X^{-1}([-\infty, c])\right) \\ &= \begin{cases} P(\emptyset) & \text{se } c < 0 \\ P(\{coroa\}) & \text{se } 0 \leq c < 1 \\ P(\Omega) & \text{se } c \geq 1 \end{cases} \\ &= \begin{cases} 0 & \text{se } c < 0 \\ \frac{1}{2} & \text{se } 0 \leq c < 1 \\ 1 & \text{se } c \geq 1 \end{cases} . \end{aligned}$$



## 2. Lei de probabilidade e função de distribuição.

Propriedades de uma função de distribuição:

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r. e  $F$  a função de distribuição de  $X$ .  $F$  tem as seguintes propriedades:

- i)  $F$  é monótona não-decrescente;
- ii)  $\lim_{x \rightarrow -\infty} F(x) = 0$  e  $\lim_{x \rightarrow +\infty} F(x) = 1$ ;
- iii) para todo o  $a, b \in \mathbb{R}$ , com  $a < b$ , tem-se

$$P_X([a, b]) \equiv P(a < X \leq b) = F(b) - F(a)$$

em que  $P_X$  é a lei de probabilidade da v.a.r.  $X$ ;

- iv)  $F$  é contínua à direita;
- v)  $F$  é contínua em  $x_0 \in \mathbb{R}$  sse  $P_X(\{x_0\}) \equiv P(X = x_0) = 0$ ;
- vi)  $F$  tem, quando muito, uma infinidade numerável de pontos de descontinuidade.

[Demonstração de i)-iii)] Ver Folhas Práticas .

[Demonstração de vi)] Ver livro Lopes & Gonçalves, 2000.

## 2. Lei de probabilidade e função de distribuição.

Demonstração de iv): Pretende-se mostrar que, para todo o  $a \in \mathbb{R}$ ,

$$\lim_{c \rightarrow a^+} F(c) = F(a).$$

Como  $F$  é monótona e limitada, existe  $\lim_{c \rightarrow a^+} F(c)$ .

Vamos considerar uma sucessão  $(c_n)_{n \in \mathbb{N}} \searrow a$ , i.e., uma sucessão de números reais decrescente e convergente para  $a$ .

Observe que

$$\lim_{n \rightarrow \infty} F(c_n) = \lim_{n \rightarrow \infty} P_X([-\infty, c_n]) = P_X\left(\bigcap_{n \in \mathbb{N}} [-\infty, c_n]\right) = P_X([-\infty, a]) = F(a)$$

A segunda igualdade deve-se ao facto de  $([-\infty, c_n])_{n \in \mathbb{N}}$  ser uma sucessão decrescente de elementos de  $\mathcal{B}(\mathbb{R})$  e de  $P_X$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ .

Pela unicidade do limite, concluímos então que

$$\lim_{c \rightarrow a^+} F(c) = F(a).$$

## 2. Lei de probabilidade e função de distribuição.

Demonstração de v): Já vimos que  $F$  é contínua à direita. Falta apenas provar que  $F$  é contínua à esquerda de  $x_0$  sse  $P_X(\{x_0\}) = 0$ . Observe que

$$\begin{aligned}P_X(\{x_0\}) &= P_X([-\infty, x_0]) - P_X([-\infty, x_0[)) \\&= F(x_0) - P_X\left(\bigcup_{n \in \mathbb{N}} \left[-\infty, x_0 - \frac{1}{n}\right]\right) \\&= F(x_0) - \lim_{n \rightarrow \infty} P_X\left(\left[-\infty, x_0 - \frac{1}{n}\right]\right) \\&= F(x_0) - \lim_{n \rightarrow \infty} F\left(x_0 - \frac{1}{n}\right) \\&= F(x_0) - \lim_{c \rightarrow x_0^-} F(c)\end{aligned}$$

A terceira igualdade deve-se ao facto de  $([-\infty, x_0 - \frac{1}{n}])_{n \in \mathbb{N}}$  ser uma sucessão crescente de elementos de  $\mathcal{B}(\mathbb{R})$  e  $P_X$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ .

Concluimos então que  $P_X(\{x_0\}) = 0 \Leftrightarrow \lim_{c \rightarrow x_0^-} F(c) = F(x_0)$ . c.q.d.

### 3. Variáveis Aleatórias Reais Discretas

#### 3.1 Definição. Função de Probabilidade.

No que se segue,  $(\Omega, \mathcal{A}, P)$  é um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  é uma v.a.r. e  $P_X$  representa a lei de probabilidade de  $X$ .

##### Definição

Se existe um subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  finito ou infinito numerável tal que  $P_X(D) \equiv P(X \in D) = 1$ , diz-se que  $X$  é uma v.a.r. discreta e que  $P_X$  é uma lei de probabilidade discreta.

Ao menor subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  que verifica a condição  $P_X(D) = 1$ , chama-se *contradomínio* ou *suporte* da v.a.r.  $X$  e denota-se por  $C_X$ .

## 3. Variáveis Aleatórias Reais Discretas

### 3.1 Definição. Função de Probabilidade.

No que se segue,  $(\Omega, \mathcal{A}, P)$  é um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  é uma v.a.r. e  $P_X$  representa a lei de probabilidade de  $X$ .

#### Definição

Se existe um subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  finito ou infinito numerável tal que  $P_X(D) \equiv P(X \in D) = 1$ , diz-se que  $X$  é uma v.a.r. discreta e que  $P_X$  é uma lei de probabilidade discreta.

Ao menor subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  que verifica a condição  $P_X(D) = 1$ , chama-se *contradomínio* ou *suporte* da v.a.r.  $X$  e denota-se por  $C_X$ .

#### Teorema

Se  $P_X$  é uma lei de probabilidade discreta então o contradomínio de  $X$  é o conjunto de pontos de descontinuidade da respectiva função de distribuição.

[Demonstração] Ver livro de Lopes & Gonçalves

## 3.1 Definição. Função de Probabilidade.

### Teorema

Seja  $X$  uma v.a.r. discreta de contradomínio  $C_X$ . A lei de probabilidade  $P_X$  é caracterizada pela função  $f : \mathbb{R} \rightarrow [0, 1]$  definida por

$$f(a) = \begin{cases} P_X(\{a\}) \equiv P(X = a) & \text{se } a \in C_X \\ 0 & \text{se c.c.} \end{cases}.$$

$f$  é designada de *função de probabilidade da v.a.r.  $X$*  ou *função de probabilidade da lei  $P_X$* . Também é usual chamar *função massa de probabilidade de  $X$* .

[Demonstração] É evidente que dada  $P_X$  a função  $f$  fica completamente determinada. Suponhamos agora que  $f$  é conhecida e provemos que  $P_X$  também fica completamente definida. Ora, tem-se que,  $\forall E \in \mathcal{B}(\mathbb{R})$ ,

$$\begin{aligned} P_X(E) &= P_X(E \cap (C_X \cup \overline{C_X})) = P_X(\underbrace{E \cap C_X}_{\text{numerável}}) + \underbrace{P_X(E \cap \overline{C_X})}_{=0} \\ &= \sum_{x \in (E \cap C_X)} P_X(\{x\}) = \sum_{x \in (E \cap C_X)} f(x) \end{aligned} \quad \text{c.q.d.}$$

## 3.1 Definição. Função de Probabilidade.

Observação:

Uma vez conhecida a função de probabilidade,  $f$ , da v.a.r.  $X$  de contra-domínio  $C_X = \{x_1, x_2, \dots, x_n, \dots\}$ , com  $x_1 < x_2 < \dots < x_n < \dots$ , a função de distribuição de  $X$  obtém-se do seguinte modo:

$$\begin{aligned} F_X(c) &= P_X([-\infty, c]) \equiv P(X \leq c) = \sum_{x_i \in C_X : x_i \leq c} f(x_i) \\ &= \begin{cases} 0 & \text{se } c < x_1 \\ f(x_1) & \text{se } x_1 \leq c < x_2 \\ f(x_1) + f(x_2) & \text{se } x_2 \leq c < x_3 \\ \vdots & \\ f(x_1) + f(x_2) + \dots + f(x_n) & \text{se } x_n \leq c < x_{n+1} \\ \vdots & \end{cases} \end{aligned}$$

## 3.1 Definição. Função de Probabilidade.

Observe ainda que, se  $X$  é uma v.a.r. discreta, de contradomínio  $C_X$  e função de probabilidade  $f$ , então:

- 1 qualquer que seja  $E \in \mathcal{B}(\mathbb{R})$ , tem-se

$$P_X(E) \equiv P(X \in E) = \sum_{a \in (C_X \cap E)} f(a),$$

como já foi visto na demonstração do último teorema e usado na construção da função de distribuição.

- 2 da definição de  $C_X$ , resulta obviamente que

$$\sum_{a \in C_X} f(a) = 1.$$



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Nesta secção vamos estudar algumas leis de probabilidade discretas que são frequentemente utilizadas na prática.

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Nesta secção vamos estudar algumas leis de probabilidade discretas que são frequentemente utilizadas na prática.

**I) Lei Binomial com parâmetros  $n$  e  $p$ , com  $n \in \mathbb{N}$ ,  $p \in ]0, 1[$ :**

Seja  $(\Omega, \mathcal{F}, P)$  o espaço de probabilidade de uma experiência aleatória,  $\xi$ , e seja  $S$  um acontecimento que, numa realização de  $\xi$ , ocorre com probabilidade  $0 < p < 1$ , i.e.,  $S \in \mathcal{F}$  tal que  $P(S) = p$ .

Considere agora a v.a.r.  $X$  que representa o número de vezes que o  $S$  ocorre em  $n$  repetições independentes da experiência  $\xi$ . Tem-se que  $X$  é uma v.a.r. discreta, de contradomínio  $C_X = \{0, 1, \dots, n\}$  e com função de probabilidade,  $f : \mathbb{R} \rightarrow [0, 1]$ , dada por

$$f(k) = \begin{cases} \binom{n}{k} p^k (1-p)^{n-k} & \text{se } k \in \{0, 1, \dots, n\} \\ 0 & \text{se c.c.} \end{cases}.$$

Nestas condições, diz-se que a v.a.r.  $X$  segue a lei Binomial com parâmetros  $n$  e  $p$ , e abrevia-se por  $X \sim \text{Bin}(n, p)$ .

Nota: O acontecimento  $S$  é usualmente designado de "sucesso".

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### II) Lei de Bernoulli com parâmetro $p, p \in ]0, 1[$ :

Seja  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $A \in \mathcal{F}$  tal que  $P(A) = p$ , com  $0 < p < 1$ .

Já vimos que a função  $X : \Omega \rightarrow \mathbb{R}$  definida por

$$X(w) = \begin{cases} 0 & \text{se } w \notin A \\ 1 & \text{se } w \in A \end{cases}$$

é uma v.a.r. e a sua lei de probabilidade,  $P_X$ , é tal que  $P_X(\{1\}) = p$  e  $P_X(\{0\}) = 1 - p$ . Como  $p \in ]0, 1[$ , temos que  $C_X = \{0, 1\}$ , pelo que  $X$  é uma v.a.r. discreta. A função de probabilidade de  $X, f : \mathbb{R} \rightarrow [0, 1]$ , é dada por

$$f(a) = \begin{cases} p & \text{se } a = 1 \\ 1 - p & \text{se } a = 0 \\ 0 & \text{se } a \notin \{0, 1\} \end{cases}.$$

Nestas condições, diz-se que  $X$  segue a lei de Bernoulli com parâmetro  $p$ , e abrevia-se por  $X \sim \text{Bernoulli}(p)$ .

Observação: A lei *Bernoulli*( $p$ ) coincide com a lei *Bin*( $1, p$ ).

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### III) Lei Hipergeométrica com parâmetros $N$ , $M$ e $n$ :

Suponha que numa caixa estão  $N$  elementos, dos quais  $0 \leq M \leq N$  possuem um certo atributo  $A$  e os restantes  $N - M$  elementos não têm este atributo.

Considere a experiência aleatória que consiste em recolher uma amostra, sem reposição, de  $n$  elementos retirados da caixa e seja  $X$  a v.a.r. que representa o número de elementos da amostra que possuem o atributo  $A$ . Tem-se que  $X$  é uma v.a.r. discreta, de contradomínio

$$C_X = \{\max(0, n - (N - M)), \dots, \min(n, M)\}$$

e função de probabilidade

$$f(k) = \begin{cases} \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} & \text{se } k \in C_X \\ 0 & \text{se c.c.} \end{cases}$$

Nestas condições, diz-se que  $X$  segue a lei Hipergeométrica com parâmetros  $N$ ,  $M$  e  $n$ , e abrevia-se por  $X \sim HG(N, M, n)$ .

Nota: Se a amostra é feita com reposição, tem-se que  $X \sim \text{Bin}\left(n, \frac{M}{N}\right)$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Exemplo: Considere um lote de 10 peças, em que 4 são defeituosas e as restantes 6 não são defeituosas.

- Se escolhermos, ao acaso e sem reposição, 8 peças deste lote e considerarmos  $X$  a v.a.r. que representa o número de peças defeituosas entre as 8 escolhidas, temos que

$$X \sim HG(10, 4, 8)$$

e que  $C_X = \{2, 3, 4\}$ .

- Se escolhermos, ao acaso e com reposição, 8 peças deste lote e considerarmos  $Y$  a v.a.r. que representa o número de peças defeituosas entre as 8 escolhidas, temos que

$$Y \sim Bin\left(8, \frac{4}{10}\right)$$

e que  $C_Y = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

[Fim da matéria para o 1.º teste]

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### IV) Lei de Poisson com parâmetro $\lambda$ , com $\lambda \in \mathbb{R}^+$ :

Seja  $(X_n)_{n \in \mathbb{N}}$  uma sucessão de v.a.r.'s, todas definidas sobre o mesmo espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ , e tais que  $X_n \sim \text{Bin}(n, p_n)$  com os parâmetros a satisfazer

$$\lim_{n \rightarrow +\infty} p_n = 0 \text{ e } \lim_{n \rightarrow +\infty} np_n = \lambda,$$

com  $\lambda \in \mathbb{R}^+$ .

Nestas condições, tem-se que

$$\frac{P(X_n = k)}{P(X_n = k - 1)} = \frac{\binom{n}{k} p_n^k (1 - p_n)^{n-k}}{\binom{n}{k-1} p_n^{k-1} (1 - p_n)^{n-k+1}} = \frac{n - k + 1}{k} \frac{p_n}{1 - p_n} \xrightarrow{n \rightarrow +\infty} \frac{\lambda}{k}.$$

Isto permite-nos concluir que, para  $n$  suficientemente grande, a função de probabilidade da v.a.r.  $X_n$  comporta-se como a de uma v.a.r. discreta,  $Y$ , de contradomínio  $C_Y = \mathbb{N}_0$ , e tal que

$$P(Y = k) = \frac{\lambda}{k} P(Y = k - 1), \quad k \in \mathbb{N}.$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Trabalhando esta última igualdade, concluímos que

$$P(Y = k) = \frac{\lambda}{k} P(Y = k - 1) = \frac{\lambda^2}{k(k-1)} P(Y = k - 2) = \dots = \frac{\lambda^k}{k!} P(Y = 0).$$

Como  $C_Y = \mathbb{N}_0$ , temos

$$1 = \sum_{k=0}^{+\infty} P(Y = k) \Leftrightarrow 1 = \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} P(Y = 0) \Leftrightarrow 1 = P(Y = 0) e^{\lambda} \Leftrightarrow P(Y = 0) = e^{-\lambda}$$

Concluimos assim que, para todo o  $k \in \mathbb{N}_0$ ,  $P(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}$  e que a função de probabilidade de  $Y$  é dada por

$$f(k) = \begin{cases} \frac{\lambda^k}{k!} e^{-\lambda} & \text{se } k \in \mathbb{N}_0 \\ 0 & \text{se c.c.} \end{cases}.$$

Nestas condições, diz-se que  $Y$  segue a lei de Poisson de parâmetro  $\lambda$ , e abrevia-se por  $Y \sim \text{Poisson}(\lambda)$ .



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### Nota:

A lei de Poisson é adequada para modelar o número de ocorrências de um fenómeno raro (i.e. um fenómeno que tem baixa probabilidade de ocorrer) quando não limitamos o número de repetições da experiência aleatória.

Em particular, a função de probabilidade da lei de Poisson é usada para obter um valor aproximado da função de probabilidade de uma v.a.r.

$Z \sim \text{Bin}(n, p)$  quando  $n$  é grande e  $p$  é pequeno. O parâmetro  $\lambda$  a utilizar na aproximação será igual a  $n \times p$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### V) Lei Uniforme num conjunto finito $U$ :

Seja  $U = \{u_1, u_2, \dots, u_n\}$  um subconjunto real finito, com  $n$  elementos. Diz-se que uma v.a.r.  $X$  tem lei Uniforme no conjunto  $U$ , abrevia-se por  $X \sim \text{Uniforme}(U)$ , se a função de probabilidade é dada por

$$f(a) = \begin{cases} \frac{1}{n} & \text{se } a \in U \\ 0 & \text{se c.c.} \end{cases}.$$

Na prática, esta lei é utilizada sempre que se escolhe, ao acaso, um elemento do conjunto  $U$  e os diferentes elementos de  $U$  têm igual probabilidade de serem escolhidos.

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### V) Lei Geométrica, com parâmetro $p$ :

Considere uma experiência aleatória na qual um certo acontecimento, que designamos por “sucesso”, ocorre com probabilidade  $0 < p < 1$  (e ocorre “insucesso” com probabilidade  $1 - p$ ). Suponhamos agora que se repete esta experiência, sempre nas mesmas condições (i.e., repetições independentes) e seja  $T$  a v.a. que representa o número de vezes que se efetua a experiência até ocorrer “sucesso” pela primeira vez.

Naturalmente, tem-se que  $T$  é discreta e que  $C_T = \{1, 2, \dots\} = \mathbb{N}$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

$$P(T = 3) = P(A_1 \cap A_2 \cap \overline{A_3}) = P(A_1) \times P(A_2) \times P(\overline{A_3}) = (1 - p)^2 p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

$$P(T = 3) = P(A_1 \cap A_2 \cap \overline{A_3}) = P(A_1) \times P(A_2) \times P(\overline{A_3}) = (1 - p)^2 p;$$

$$\vdots$$

$$P(T = k) = P(A_1 \cap A_2 \cap \dots \cap A_{k-1} \cap \overline{A_k}) = p(1 - p)^{k-1}, \quad k \in \mathbb{N}$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Tem-se assim a seguinte definição:

### Definição

Sejam  $T$  uma v.a. discreta e  $p \in ]0, 1[$ .

Diz-se que  $T$  segue a *distribuição Geométrica com parâmetro  $p$* , e abrevia-se por  $T \sim Geo(p)$ , se o seu contradomínio é  $\mathbb{N}$  e a sua função de probabilidade é dada por

$$f(k) = \begin{cases} p(1-p)^{k-1} & \text{se } k \in \mathbb{N} \\ 0 & \text{se c.c.} \end{cases}$$

**Observações:** Se  $T \sim Geo(p)$ ,

1) Facilmente se verifica que, para todo o  $k \in \mathbb{N}$ ,

$$P(T > k) = (1-p)^k.$$

2)  $T$  tem a conhecida propriedade de falta de memória, i.e.,

$$P(T = k + n | T > k) = P(T = n),$$

para todo o  $k, n \in \mathbb{N}$ .



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Exemplo/Exercício: Imagine que um bêbado tem  $n$  chaves na sua carteira e que, ao chegar a casa, não consegue identificar a única chave que abre a porta. Como está tão bêbado, de cada vez que ele tenta uma chave que não é a certa, não consegue colocá-la de lado pelo que na tentativa seguinte volta a ter  $n$  chaves disponíveis para a escolha. Calcule a probabilidade de ele:

- i) acertar à primeira;
- ii) acertar pela primeira vez na terceira tentativa;
- iii) errar as primeiras 5 tentativas;
- iv) acertar pela primeira vez na oitava tentativa, sabendo que errou nas primeiras 5.

Sugestão: Identificar uma v.a. relevante para o problema e que tenha distribuição Geométrica.

# 4. Variáveis aleatórias reais (absolutamente) contínuas

## 4.1 Leis Difusas

### Definição

Seja  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r..  $X$  diz-se difusa se a sua lei de probabilidade,  $P_X$ , for uma medida de probabilidade difusa sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , i.e., se  $P_X$  for tal que

$$P_X(\{a\}) \equiv P(X = a) = 0, \forall a \in \mathbb{R}.$$

Nota: Se  $X$  é uma v.a.r. difusa então a função de distribuição de  $X$ ,  $F_X$ , é uma função contínua. Ver propriedades da função de distribuição.

Entre as leis difusas sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , há um subconjunto muito importante e que vamos estudar: o das leis de probabilidade absolutamente contínuas. Tais leis caracterizam-se à custa de uma função, real de variável real, chamada de *função densidade de probabilidade*.

## 4.2 Leis absolutamente contínuas

### Definição

Uma função  $f : \mathbb{R} \rightarrow \mathbb{R}$  diz-se uma função densidade de probabilidade sobre  $\mathbb{R}$  se:

- $f(x) \geq 0, \forall x \in \mathbb{R}$ ;
- $f$  é integrável e  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

Exemplos: Das funções indicadas no Exercício 5, da Folha Prática 1, quais as que são funções densidade de probabilidade?

## 4.2 Leis absolutamente contínuas

### Definição

Uma função  $f : \mathbb{R} \rightarrow \mathbb{R}$  diz-se uma função densidade de probabilidade sobre  $\mathbb{R}$  se:

- $f(x) \geq 0, \forall x \in \mathbb{R}$ ;
- $f$  é integrável e  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

Exemplos: Das funções indicadas no Exercício 5, da Folha Prática 1, quais as que são funções densidade de probabilidade?

- i), iv), v) e vi) são funções densidade de probabilidade;
- iii) não é uma função densidade de probabilidade porque não é integrável.
- ii), vii) e viii) não são funções densidade de probabilidade porque não satisfazem a condição  $\int_{-\infty}^{+\infty} f(x)dx = 1$ ;

## 4.2 Leis absolutamente contínuas

### Definição

Uma v.a.r.  $X$  diz-se absolutamente contínua se a sua lei de probabilidade,  $P_X$ , é uma lei absolutamente contínua sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , i.e., se existe uma função densidade de probabilidade sobre  $\mathbb{R}$ ,  $f$ , tal que

$$\forall_{a,b \in \mathbb{R}, a < b}, P_X(]a, b[) \equiv P(X \in ]a, b[) = \int_a^b f(x)dx.$$

À função  $f$  chamamos função densidade de probabilidade da v.a.r.  $X$  (ou da lei de probabilidade  $P_X$ ). Ao menor elemento de  $\mathcal{B}(\mathbb{R})$  onde a função  $f$  é estritamente positiva chamamos suporte ou contradomínio de  $X$ .

Observação: É possível mostrar que toda a função densidade de probabilidade sobre  $\mathbb{R}$  determina uma única medida de probabilidade  $Q$  sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  absolutamente contínua que verifica a condição

$$\forall_{a,b \in \mathbb{R}, a < b}, Q(]a, b[) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

### Teorema

Se  $Q$  é uma lei de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  absolutamente contínua então  $Q$  é difusa.

[Demonstração]: Pretende-se provar que  $Q(\{a\}) = 0$ , para todo o  $a \in \mathbb{R}$ . Comece por observar que

$$\{a\} = \bigcap_{n \in \mathbb{N}} \left] a - \frac{1}{n}, a + \frac{1}{n} \right[.$$

Sendo  $Q$  absolutamente contínua então  $Q$  admite uma função densidade de probabilidade e seja  $f$  essa função. Tem-se, então, que

$$Q(\{a\}) = \lim_{n \rightarrow +\infty} Q\left(\left] a - \frac{1}{n}, a + \frac{1}{n} \right[ \right) = \lim_{n \rightarrow +\infty} \int_{a - \frac{1}{n}}^{a + \frac{1}{n}} f(x) dx = 0.$$

A primeira igualdade deve-se ao facto de  $Q$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  e a segunda deve-se ao facto de  $Q$  ser uma lei absolutamente contínua com função densidade de probabilidade  $f$ . c.q.d.

## 4.2 Leis absolutamente contínuas

Observação: Deste último teorema, resulta trivialmente que, se  $X$  é uma v.a.r. absolutamente contínua, então a respectiva lei,  $P_X$ , satisfaz as seguintes igualdades: para todo  $a, b \in \mathbb{R}$ ,  $a < b$ ,

$$P_X(]a, b[) = P_X([a, b[) = P_X(]a, b]) = P_X([a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(X \in ]a, b[) = P(X \in [a, b[) = P(X \in ]a, b]) = P(X \in [a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

Observação: Deste último teorema, resulta trivialmente que, se  $X$  é uma v.a.r. absolutamente contínua, então a respectiva lei,  $P_X$ , satisfaz as seguintes igualdades: para todo  $a, b \in \mathbb{R}$ ,  $a < b$ ,

$$P_X(]a, b[) = P_X([a, b[) = P_X(]a, b]) = P_X([a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(X \in ]a, b[) = P(X \in [a, b[) = P(X \in ]a, b]) = P(X \in [a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b) = \int_a^b f(x)dx.$$

O teorema seguinte caracteriza as leis de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  que são absolutamente contínuas. Em particular, é estabelecida uma relação entre a função densidade de probabilidade e a função de distribuição de uma tal lei.



## 4.2 Leis absolutamente contínuas

### Teorema

Uma condição necessária e suficiente para que uma v.a.r.  $X$  seja absolutamente contínua é que a sua função de distribuição,  $F_X$ , verifique a seguinte condição

$$\forall c \in \mathbb{R}, F_X(c) = P_X(]-\infty, c]) \equiv P(X \leq c) = \int_{-\infty}^c f(x)dx,$$

para alguma função densidade de probabilidade  $f$ .

[Demonstração]

( $\Rightarrow$ ) Suponhamos que  $X$  é uma v.a.r. absolutamente contínua. Então existe  $f$ , uma função densidade de probabilidade sobre  $\mathbb{R}$ , tal que

$$\forall a, b \in \mathbb{R} : a < b, \quad P_X(]a, b[) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

Então, para todo o  $c \in \mathbb{R}$ ,

$$\begin{aligned}F_X(c) &= P_X([-\infty, c]) = P_X([-\infty, c[) = P_X\left(\bigcup_{n \in \mathbb{N}} ]-n, c[ \right) \\&= \lim_{n \rightarrow +\infty} P_X(]-n, c[) \\&= \lim_{n \rightarrow +\infty} \int_{-n}^c f(x) dx \\&= \int_{-\infty}^c f(x) dx.\end{aligned}$$

Observe que a segunda igualdade deve-se ao facto de  $P_X$  ser uma lei difusa; a quarta igualdade deve-se a  $P_X$  ser medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (Propriedade 6)); a penúltima igualdade deve-se a  $X$  ser absolutamente contínua com função densidade de probabilidade  $f$ ; a última igualdade deve-se ao facto de  $f$  ser integrável.

## 4.2 Leis absolutamente contínuas

( $\Leftarrow$ ) Suponhamos agora que  $X$  é uma v.a.r. cuja função de distribuição,  $F_X$ , é dada por

$$\forall c \in \mathbb{R}, \quad F_X(c) = \int_{-\infty}^c f(x)dx$$

para alguma função densidade de probabilidade  $f$ . Se provarmos que

$$\forall a, b \in \mathbb{R} : a < b, \quad P_X(]a, b[) = \int_a^b f(x)dx$$

fica demonstrado que  $X$  é uma v.a.r. absolutamente contínua. Para provar isto, basta mostrar as seguintes igualdades:

- a)  $P_X(]a, b]) = \int_a^b f(x)dx,$
- b)  $P_X(\{b\}) = 0.$

## 4.2 Leis absolutamente contínuas

Ora

$$P_X([a, b]) = F_X(b) - F_X(a) = \int_{-\infty}^b f(x)dx - \int_{-\infty}^a f(x)dx = \int_a^b f(x)dx,$$

ficando assim provado a). Observe que a primeira igualdade se deve a uma das propriedades de uma função de distribuição (propriedade iii)).

Adicionalmente,

$$\begin{aligned} P_X(\{b\}) &= P_X\left(\bigcap_{n \in \mathbb{N}} \left[b - \frac{1}{n}, b + \frac{1}{n}\right]\right) \\ &= \lim_{n \rightarrow +\infty} P_X\left(\left[b - \frac{1}{n}, b + \frac{1}{n}\right]\right) \\ &= \lim_{n \rightarrow +\infty} \int_{b - \frac{1}{n}}^{b + \frac{1}{n}} f(x)dx \\ &= 0, \end{aligned}$$

e fica provado b). Observe que a segunda igualdade se deve ao facto de  $P_X$  ser medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (Propriedade VI)) e a penúltima igualdade faz uso de a).

c.q.d.

## 4.2 Leis absolutamente contínuas

O último teorema caracteriza as v.a.r.'s absolutamente contínuas e estabelece como se determina a função de distribuição à custa da função densidade de probabilidade.

## 4.2 Leis absolutamente contínuas

O último teorema caracteriza as v.a.r.'s absolutamente contínuas e estabelece como se determina a função de distribuição à custa da função densidade de probabilidade.

## 4.2 Leis absolutamente contínuas

O último teorema caracteriza as v.a.r.'s absolutamente contínuas e estabelece como se determina a função de distribuição à custa da função densidade de probabilidade.

A questão que agora se coloca é: como obter a função densidade de probabilidade,  $f$ , à custa da função de distribuição,  $F$ ?

## 4.2 Leis absolutamente contínuas

O último teorema caracteriza as v.a.r.'s absolutamente contínuas e estabelece como se determina a função de distribuição à custa da função densidade de probabilidade.

A questão que agora se coloca é: como obter a função densidade de probabilidade,  $f$ , à custa da função de distribuição,  $F$ ?

É possível demonstrar [ver Lopes & Gonçalves] que a função de distribuição de uma v.a.r. absolutamente contínua é derivável excepto, quando muito, num subconjunto infinito numerável de  $\mathbb{R}$ . Mais, pode-se ainda provar que:

- 1 Se  $F'$  é contínua então  $f(x) = F'(x)$ ,  $\forall x \in \mathbb{R}$ .
- 2 Se  $F'$  é contínua excepto, quando muito, num subconjunto infinito numerável  $D \subset \mathbb{R}$ , e se  $F'$  é limitada então

$$f(x) = F'(x), \text{ para todo o } x \in \mathbb{R} \setminus D.$$

Neste último caso, para os pontos  $x \in D$  convencionam-se  $f(x) = 0$ .



## 4.2 Leis absolutamente contínuas

Na verdade, podemos atribuir um qualquer valor não negativo à função  $f$  no conjunto  $D$ .

Uma vez que  $D$  é, quando muito, infinito numerável, qualquer que seja o valor (não negativo) atribuído a  $f(x)$  em pontos  $x \in D$ , tem-se sempre

$$P_X(D) = 0.$$

Deste modo, podem existir várias funções densidade de probabilidade para uma mesma v.a.r.  $X$  absolutamente contínua. No entanto, elas só podem diferir umas das outras num subconjunto finito ou infinito numerável de  $\mathbb{R}$ .

## 4.3 Leis de probabilidade contínuas mais conhecidas

Nesta secção vamos estudar algumas leis de probabilidade absolutamente contínuas que são frequentemente utilizadas na prática.

## 4.3 Leis de probabilidade contínuas mais conhecidas

Nesta secção vamos estudar algumas leis de probabilidade absolutamente contínuas que são frequentemente utilizadas na prática.

**I) Lei Uniforme no intervalo**  $[a, b]$ ,  $a, b \in \mathbb{R}$ ,  $a < b$ :

Diz-se que uma v.a.r. absolutamente contínua,  $X$ , segue a lei Uniforme no intervalo  $[a, b]$ , abrevia-se por  $X \sim U([a, b])$ , se a função densidade de probabilidade de  $X$  é dada por

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{se c.c.} \end{cases}.$$

Esta lei atribui a mesma probabilidade a intervalos de igual amplitude contidos em  $[a, b]$ . De facto, se  $]c, d[ \subseteq [a, b]$  tem-se que

$$P(X \in ]c, d[) = \int_c^d f(x)dx = \left[ \frac{x}{b-a} \right]_c^d = \frac{d-c}{b-a} = \frac{\text{amplitude de } ]c, d[}{b-a}.$$

## 4.3 Leis de probabilidade contínuas mais conhecidas

Se  $X \sim U([a, b])$  então a respectiva função de distribuição é dada por

$$F(c) = P_X([-\infty, c]) = \int_{-\infty}^c f(x)dx = \begin{cases} 0 & \text{se } c < a \\ \frac{c-a}{b-a} & \text{se } a \leq c \leq b \\ 1 & \text{se } c > b. \end{cases}$$

Uma das utilizações mais importantes da lei uniforme é apresentada no teorema da transformação uniformizante, que diz o seguinte:

### Teorema [ Transformação Uniformizante]

Seja  $X$  uma v.a.r. absolutamente contínua e cuja função de distribuição,  $G$ , é estritamente crescente. Então a v.a.r.  $Y = G(X) \sim U([0, 1])$ .

[Demonstração] A função de distribuição de  $Y$ ,  $F_Y$ , é dada por

$$F_Y(c) = P(G(X) \leq c) = \begin{cases} 0 & \text{se } c < 0 \\ P(X \leq G^{-1}(c)) = G(G^{-1}(c)) = c & \text{se } 0 \leq c \leq 1 \\ 1 & \text{se } c > 1 \end{cases},$$

que coincide com a função de distribuição da lei  $U([0, 1])$ . c.q.d.

## 4.3 Leis de probabilidade contínuas mais conhecidas

### II) Lei Exponencial de parâmetro $\lambda$ , $\lambda \in \mathbb{R}^+$ :

Diz-se que uma v.a.r. absolutamente contínua,  $X$ , segue a lei Exponencial de parâmetro  $\lambda$ , com  $\lambda \in \mathbb{R}^+$ , abrevia-se por  $X \sim \text{Exp}(\lambda)$ , se a função densidade de probabilidade de  $X$  é dada por

$$f(x) = \begin{cases} 0 & \text{se } x < 0 \\ \lambda e^{-\lambda x} & \text{se } x \geq 0 \end{cases}.$$

Se  $X \sim \text{Exp}(\lambda)$  então a respectiva função de distribuição é dada por

$$F(c) = P_X([-\infty, c]) = \int_{-\infty}^c f(x)dx = \begin{cases} 0 & \text{se } c < 0 \\ 1 - e^{-\lambda c} & \text{se } c \geq 0 \end{cases}.$$

A propriedade mais importante da lei Exponencial é a conhecida falta de memória: para todo o  $x, t \in \mathbb{R}^+$  tem-se

$$P(T > t + x | T > t) = P(T > x).$$

Observação: Esta propriedade é partilhada com a lei Geométrica (que é uma lei discreta) [ver Secção 3.2].

## 4.3 Leis de probabilidade contínuas mais conhecidas

**III) Lei Normal (ou Gaussiana) de parâmetros  $\mu$  e  $\sigma^2$ ,  $\mu \in \mathbb{R}$  e  $\sigma \in \mathbb{R}^+$ :**  
Diz-se que uma v.a.r. absolutamente contínua,  $X$ , segue a lei Normal de parâmetros  $\mu$  e  $\sigma^2$ , abrevia-se por  $X \sim N(\mu, \sigma^2)$ , se a função densidade de probabilidade de  $X$  for dada por

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left( \frac{x - \mu}{\sigma} \right)^2 \right\}, \quad x \in \mathbb{R}.$$

Nota: A lei  $N(0, 1)$  é designada de lei *normal standard* ou lei *normal centrada e reduzida*.

A lei Normal tem várias propriedades interessantes. Vamos começar por provar que a função  $f$  acima é realmente uma função densidade de probabilidade sobre  $\mathbb{R}$ , i.e., que  $f(x) \geq 0$  (trivial) e que

$$\int_{-\infty}^{+\infty} f(x) dx = 1.$$

## 4.3 Leis de probabilidade contínuas mais conhecidas

Vamos começar por considerar a função

$$g(x) = \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2}x^2 \right\}, \quad x \in \mathbb{R}$$

e provar que  $I = \int_{-\infty}^{+\infty} g(x)dx = 1$ . Como  $g(x) > 0, \forall x \in \mathbb{R}$ , se provarmos que  $I^2 = 1$  teremos que a única possibilidade é  $I = 1$ . E, de facto:

$$\begin{aligned} I^2 &= \int_{-\infty}^{+\infty} g(x)dx \times \int_{-\infty}^{+\infty} g(y)dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{1}{2\pi} \exp \left\{ -\frac{1}{2}(x^2 + y^2) \right\} dx dy \\ &\stackrel{(*)}{=} \int_0^{+\infty} \int_0^{2\pi} \frac{1}{2\pi} \exp \left\{ -\frac{1}{2}r^2 \right\} r d\theta dr = \int_0^{+\infty} \frac{r}{2\pi} \exp \left\{ -\frac{1}{2}r^2 \right\} dr [\theta]_0^{2\pi} \\ &= \int_0^{+\infty} r \exp \left\{ -\frac{1}{2}r^2 \right\} dr = \left[ -\exp \left\{ -\frac{1}{2}r^2 \right\} \right]_0^{+\infty} = 1. \end{aligned}$$

## 4.3 Leis de probabilidade contínuas mais conhecidas

A igualdade assinalada com (\*) deve-se à chamada substituição em coordenadas polares:

$$\begin{cases} x &= r \cos(\theta) \\ y &= r \sin(\theta) \end{cases},$$

com  $\theta \in [0, 2\pi]$  e  $r \geq 0$ . Observe que o jacobiano associado a esta substituição é o determinante da seguinte matriz

$$J = \begin{bmatrix} \frac{\partial x}{\partial r} & \frac{\partial y}{\partial r} \\ \frac{\partial x}{\partial \theta} & \frac{\partial y}{\partial \theta} \end{bmatrix} = \begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -r \sin(\theta) & r \cos(\theta) \end{bmatrix},$$

i.e.,

$$\det(J) = r \cos^2(\theta) + r \sin^2(\theta) = r.$$



## 4.3 Leis de probabilidade contínuas mais conhecidas

Voltemos agora ao cálculo de  $\int_{-\infty}^{+\infty} f(x)dx$ .

$$\begin{aligned}\int_{-\infty}^{+\infty} f(x)dx &= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} dx \\ &\stackrel{(**)}{=} \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}y^2\right\} \sigma dy \\ &= I \\ &= 1.\end{aligned}$$

(\*\*) substituição:  $y = \frac{x-\mu}{\sigma}$ .

## 4.3 Leis de probabilidade contínuas mais conhecidas

### Algumas propriedades da lei Normal:

Sejam  $\mu \in \mathbb{R}$  e  $\sigma \in \mathbb{R}^+$ .

1) Se  $X \sim N(\mu, \sigma^2)$  então  $\frac{X-\mu}{\sigma} \sim N(0, 1)$ .

2) Se  $Z \sim N(0, 1)$  então  $\sigma Z + \mu \sim N(\mu, \sigma^2)$ .

3) A lei  $N(0, \sigma^2)$  é simétrica relativamente à origem, i.e., se  $X \sim N(0, \sigma^2)$  então

$$P(X \in [a, b]) = P(X \in [-b, -a]), \forall a, b \in \mathbb{R}, a < b.$$

4) A lei  $N(\mu, \sigma^2)$  é simétrica relativamente a  $\mu$ , i.e., se  $X \sim N(\mu, \sigma^2)$  então

$$P(X \in [\mu + a, \mu + b]) = P(X \in [\mu - b, \mu - a]), \forall a, b \in \mathbb{R}, a < b.$$

[Demonstração] (T.P.C.) Observe que as propriedades 3) e 4) são, obviamente, consequências das simetrias das respectivas funções densidade de probabilidade.

## 4.3 Leis de probabilidade contínuas mais conhecidas

Observação: A função de distribuição da lei  $N(\mu, \sigma^2)$ , dada por

$$F(c) = \int_{-\infty}^c \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} dx,$$

não tem uma expressão analítica.

No entanto, para cada  $c \in \mathbb{R}$ , é possível obter uma aproximação de  $F(c)$  recorrendo a métodos numéricos. O resultado dessa aproximação está disponível na generalidade dos software de matemática/probabilidades e estatística. Em particular, no R está disponível através da função `pnorm`. Para obter um valor aproximado de  $F(c)$  devemos executar `pnorm(c,  $\mu$ ,  $\sqrt{\sigma^2}$ )`.

## 5. Variáveis aleatórias reais com lei mista

Nesta secção, será feita uma muito breve caracterização das leis de probabilidade *mistas* ou *de mistura*: leis de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  que não são nem discretas nem difusas. Veremos também um exemplo prático de utilização de uma tal lei.

### Teorema

Seja  $H$  uma lei de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  nem discreta nem difusa. Então existem  $\alpha \in (0, 1)$ , uma lei de probabilidade discreta,  $H_1$ , e uma lei de probabilidade difusa,  $H_2$ , tais que

$$H = \alpha H_1 + (1 - \alpha) H_2.$$

Além disso, esta decomposição de  $H$  é única.

[Demonstração] Ver Lopes & Gonçalves

## 5. Variáveis aleatórias reais com lei mista

Exemplo: Seja  $X$  a v.a.r. que representa a quantidade de chuva (em metros cúbicos) que cai diariamente numa certa região do país. Sabe-se que, num qualquer dia escolhido ao acaso, a probabilidade de não chover é  $1/3$ , i.e.  $P(X = 0) = 1/3$ , e sabe-se também que, quando chove, a quantidade de chuva é uma v.a.r. absolutamente contínua que segue a lei  $Exp(1)$ , i.e.,

$$P(X \leq c | X > 0) = 1 - e^{-c}, \quad c > 0.$$

Observe que a função de distribuição de  $X$  é dada por:

$$F(c) = P(X \leq c) = \begin{cases} 0, & c < 0 \\ \frac{1}{3}, & c = 0 \\ \frac{1}{3} + \frac{2}{3}(1 - e^{-c}), & c > 0 \end{cases} = \begin{cases} 0, & c < 0 \\ \frac{1}{3} + \frac{2}{3}(1 - e^{-c}), & c \geq 0 \end{cases},$$

## 5. Variáveis aleatórias reais com lei mista

que pode ser escrita na forma

$$F(c) = \alpha F_1(c) + (1 - \alpha) F_2(c),$$

com  $\alpha = \frac{1}{3}$ ,

$$F_1(c) = \begin{cases} 0, & c < 0 \\ 1, & c \geq 0 \end{cases} \quad \text{e} \quad F_2(c) = \begin{cases} 0, & c < 0 \\ 1 - e^{-c}, & c \geq 0 \end{cases}.$$

Repare que  $F_1$  é função de distribuição de uma lei de probabilidade discreta e  $F_2$  é função de distribuição de uma lei de probabilidade absolutamente contínua (e, consequentemente, difusa). De facto,  $F_1$  corresponde à função de distribuição de uma v.a.r. discreta, cujo contradomínio é o conjunto  $\{0\}$  (é uma v.a.r. quase certa), e  $F_2$  corresponde à função de distribuição de uma v.a.r. absolutamente contínua com lei  $Exp(1)$ .

## 6. Parâmetros de localização e dispersão

Os parâmetros de localização e dispersão não caracterizam as leis de probabilidade das respetivas v.a.r.'s, como acontece, por exemplo, com a função de distribuição ou com a função de probabilidade (no caso discreto) ou com a função densidade de probabilidade (no caso absolutamente contínuo).

No entanto, estes parâmetros fornecem informação importante sobre algumas características da variável como, por exemplo: a localização na recta real, a dispersão relativamente a algum valor central (em geral a média), a concentração em determinadas partes de  $\mathbb{R}$ , etc.

## 6.1 Esperança matemática

### Definição

Seja  $X$  uma v.a.r. definida sobre o espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ .

i) Se  $X$  é discreta de contradomínio  $C_X = \{x_1, x_2, \dots, x_n, \dots\}$  e se

$$\sum_{x_i \in C_X} |x_i| P(X = x_i) < +\infty,$$

define-se a esperança matemática (ou valor médio) de  $X$ , usualmente denotada por  $E[X]$ , como sendo

$$E[X] = \sum_{x_i \in C_X} x_i P(X = x_i).$$

Se

$$\sum_{x_i \in C_X} |x_i| P(X = x_i) = +\infty$$

diz-se que  $X$  não tem esperança matemática (ou que  $E[X]$  não existe).



## 6.1 Esperança matemática

### Definição

- ii) Se  $X$  é absolutamente contínua com função densidade de probabilidade  $f$  e se

$$\int_{-\infty}^{+\infty} |x|f(x)dx < +\infty,$$

define-se a esperança matemática (ou valor médio) de  $X$ , usualmente denotada por  $E[X]$ , como sendo

$$E[X] = \int_{-\infty}^{+\infty} xf(x)dx.$$

Se

$$\int_{-\infty}^{+\infty} |x|f(x)dx = +\infty$$

diz-se que  $X$  não tem esperança matemática (ou que  $E[X]$  não existe).

## 6.1 Esperança matemática

### Observações:

- 1) Se  $X$  é uma v.a.r. discreta de contradomínio finito então  $X$  tem esperança matemática.

Mas se  $X$  é discreta com contradomínio infinito numerável então  $E[X]$  pode não existir.

Exemplo: Considere a v.a.r.  $X$ , com  $C_X = \mathbb{Z} \setminus \{0\}$  e tal que

$$P(X = n) = P(X = -n) = \frac{1}{2n(n+1)}, n \in \mathbb{N}.$$

Note que a lei de probabilidade de  $X$  está bem definida uma vez que  $P(X = n) > 0, n \in \mathbb{Z} \setminus \{0\}$ , e

$$\sum_{n \in \mathbb{Z} \setminus \{0\}} P(X = n) = 2 \sum_{n=1}^{\infty} \frac{1}{2n(n+1)} = 1.$$

$X$  não tem esperança matemática pois

$$\sum_{n \in \mathbb{Z} \setminus \{0\}} |n|P(X = n) = 2 \sum_{n=1}^{+\infty} nP(X = n) = 2 \sum_{n=1}^{+\infty} \frac{n}{2n(n+1)} = \sum_{n=1}^{+\infty} \frac{1}{n+1} = +\infty$$

## 6.1 Esperança matemática

- 2) Se  $X$  é uma v.a.r. absolutamente contínua,  $E[X]$  também pode não existir.

Exemplo: Considere uma v.a.r.  $X$ , absolutamente contínua, com função densidade de probabilidade

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, \quad x \in \mathbb{R},$$

conhecida por densidade de Cauchy.

$E[X]$  não existe pois

$$\int_{-\infty}^{+\infty} |x|f(x)dx = 2 \int_0^{+\infty} x \frac{1}{\pi} \frac{1}{1+x^2} dx \stackrel{(1)}{=} \frac{1}{\pi} [\log(1+x^2)]_0^{+\infty} = +\infty.$$

Observação: (1) a função  $\log$  utilizada é a função logaritmo neperiano.

## 6.1 Esperança matemática

Exemplos/Exercícios Folha Prática 8: Mostre que:

- i) se  $X \sim \text{Bin}(n, p)$ , com  $n \in \mathbb{N}$  e  $p \in ]0, 1[$ , então  $E[X] = np$ ;
- ii) se  $X \sim \text{Poisson}(\lambda)$ , com  $\lambda \in \mathbb{R}^+$ , então  $E[X] = \lambda$ ;
- iii) se  $X \sim N(0, 1)$  então  $E[X] = 0$ .

## 6.1 Esperança matemática

Vejam agora a definição de esperança matemática de uma função de uma v.a.r. (sendo a definição anterior um caso particular desta).

### Definição

Sejam  $X$  uma v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$  tal que  $\phi(X)$  é uma v.a.r..

i) Se  $X$  é discreta, de contradomínio  $C_X = \{x_1, x_2, \dots, x_n, \dots\}$ , e se

$$\sum_{x_i \in C_X} |\phi(x_i)| P(X = x_i) < +\infty,$$

diz-se que  $E[\phi(X)]$  existe e

$$E[\phi(X)] = \sum_{x_i \in C_X} \phi(x_i) P(X = x_i).$$

Se

$$\sum_{x_i \in C_X} |\phi(x_i)| P(X = x_i) = +\infty$$

diz-se que  $E[\phi(X)]$  não existe.

## 6.1 Esperança matemática

### Definição

- ii) Se  $X$  é absolutamente contínua, com função densidade de probabilidade  $f$ , e se

$$\int_{-\infty}^{+\infty} |\phi(x)|f(x)dx < +\infty,$$

diz-se que  $E[\phi(X)]$  existe e

$$E[\phi(X)] = \int_{-\infty}^{+\infty} \phi(x)f(x)dx.$$

Se

$$\int_{-\infty}^{+\infty} |\phi(x)|f(x)dx = +\infty$$

diz-se que  $E[\phi(X)]$  não existe.

Observação: Podemos concluir que  $E[X]$  existe sse  $E[|X|]$  existe.

## 6.1 Esperança matemática

Exemplo/Exercício: Sejam  $X \sim \text{Exp}(1)$  uma v.a.r. e  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  a função dada por

$$\phi(x) = \begin{cases} 1 - e^{-x} & \text{se } x \geq 0 \\ 0 & \text{se } x < 0 \end{cases}.$$

Mostre que a v.a.r.  $Y = \phi(X)$  tem esperança matemática e determine então  $E[Y]$ .

Obs.: Recorde que se  $X$  é um v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$  é uma função contínua, então  $\phi(X)$  também é uma v.a.r..

## 6.1 Esperança matemática

### Propriedades da esperança matemática:

- I) Sejam  $X$  uma v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$  uma função tal que  $E[\phi(X)]$  existe. Então

$$E[a\phi(X) + b] = aE[\phi(X)] + b,$$

quaisquer que sejam  $a, b \in \mathbb{R}$ .

Observe que, como consequência deste resultado, tem-se que

$$E[aX + b] = aE[X] + b$$

quando  $E[X]$  existe.

[Demonstração] Vamos fazer a demonstração apenas para o caso discreto. Caso em que  $X$  é v.a.r. absolutamente contínua - TPC.



## 6.1 Esperança matemática

Propriedades da esperança matemática (continuação):

Seja então  $X$  v.a.r. discreta de contradomínio  $C_X = \{x_1, x_2, \dots, x_n, \dots\}$ .

Então:

$$\begin{aligned} E[|a\phi(X) + b|] &= \sum_{x_i \in C_X} |a\phi(x_i) + b| P(X = x_i) \\ &\leq \sum_{x_i \in C_X} |a\phi(x_i)| P(X = x_i) + \sum_{x_i \in C_X} |b| P(X = x_i) \\ &= |a| E[|\phi(X)|] + |b| < +\infty \end{aligned}$$

Concluimos assim que  $E[a\phi(X) + b]$  existe. Vamos agora calculá-la.

$$\begin{aligned} E[a\phi(X) + b] &= \sum_{x_i \in C_X} [a\phi(x_i) + b] P(X = x_i) \\ &= \sum_{x_i \in C_X} a\phi(x_i) P(X = x_i) + \sum_{x_i \in C_X} b P(X = x_i) \\ &= aE[\phi(X)] + b \end{aligned}$$

## 6.1 Esperança matemática

Propriedades da esperança matemática (continuação):

II) Sejam  $X$  uma v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$  uma função tal que  $E[\phi(X)]$  existe. Então

$$|E[\phi(X)]| \leq E[|\phi(X)|].$$

[Demonstração] Será feita apenas para o caso discreto. Caso em que  $X$  é v.a.r. absolutamente contínua - TPC.

$$\begin{aligned} |E[\phi(X)]| &= \left| \sum_{x_i \in C_X} \phi(x_i) P(X = x_i) \right| \\ &\leq \sum_{x_i \in C_X} |\phi(x_i)| P(X = x_i) \\ &= E[|\phi(X)|] \end{aligned}$$

(c.q.d)

## 6.1 Esperança matemática

### Propriedades da esperança matemática (continuação):

- III) Sejam  $X_1, X_2, \dots, X_n$  v.a.r.'s definidas sobre o mesmo espaço de probabilidade, todas admitindo esperança matemática. Então

$$E[a_1X_1 + a_2X_2 + \dots + a_nX_n] = a_1E[X_1] + a_2E[X_2] + \dots + a_nE[X_n]$$

quaisquer que sejam as constantes reais  $a_1, a_2, \dots, a_n$ .

[Demonstração] - Ver Lopes & Gonçalves

Exemplo/Exercício Mostre que se  $X \sim N(\mu, \sigma^2)$  então  $E[X] = \mu$ .

## 6.2 Momentos, variância e desvio-padrão

Os momentos de uma v.a.r. são definidos à custa da esperança matemática de certas funções da variável em causa. Tais funções são contínuas e têm a particularidade de a sua composição com uma v.a.r. discreta (respectivamente, contínua) resultar ainda numa v.a.r. discreta (respectivamente, contínua).

### Definição [Momento de ordem $k$ de uma v.a.r.]

Sejam  $X$  uma v.a.r. e  $k \in \mathbb{N}$ .

Se  $E[X^k]$  existe, chamamos momento de ordem  $k$  ao valor de  $E[X^k]$ .

Caso  $E[X^k]$  não exista diz-se que  $X$  não tem momento de ordem  $k$ .

## 6.2 Momentos, variância e desvio-padrão

Propriedades dos momentos: Seja  $X$  uma qualquer v.a.r..

- I) Se  $E[X^k]$  existe então  $E[X^n]$  existe, para todo o  $n \leq k$ ,  $n, k \in \mathbb{N}$ .

[Demonstração] Ver Lopes & Gonçalves

- II) Seja  $k \in \mathbb{N}$ .

$E[X^k]$  existe sse, para todo o  $a \in \mathbb{R}$ ,  $E[(X - a)^k]$  existe.

[Demonstração]

( $\Leftarrow$ ) Trivial. Basta fazer  $a = 0$ .

( $\Rightarrow$ ) Usando o Binómio de Newton, tem-se que: para todo o  $a \in \mathbb{R}$ ,

$$(X - a)^k = \sum_{n=0}^k \binom{k}{n} X^n a^{k-n} (-1)^{k-n}.$$

Logo,

$$|(X - a)^k| \leq \sum_{n=0}^k \binom{k}{n} |X^n| |a^{k-n}|.$$

Por hipótese,  $E[X^k]$  existe. Então, pela propriedade anterior,  $E[|X^n|]$  existe, para todo o  $0 \leq n \leq k$ . Logo  $E[(X - a)^k]$  existe porque

$$E[|(X - a)^k|] \leq \sum_{n=0}^k \binom{k}{n} E[|X^n|] |a^{k-n}| < +\infty$$

## 6.2 Momentos, variância e desvio-padrão

### Definição [Momento centrado de ordem $k$ ]

Seja  $X$  uma v.a.r. tal que  $E[X]$  existe e seja  $k \in \mathbb{N}$ . Chama-se momento centrado de ordem  $k$ , denota-se por  $\mu_k$ , a

$$\mu_k = E[(X - E[X])^k]$$

quando  $\mu_k$  existe.

Nota:  $\mu_1 = E[X - E[X]] = E[X] - E[E[X]] = E[X] - E[X] = 0$ .

## 6.2 Momentos, variância e desvio-padrão

### Definição [Variância e desvio-padrão]

Seja  $X$  uma v.a.r.. Chama-se variância de  $X$ , denota-se por  $Var[X]$ , ao momento centrado de ordem 2 quando existe, i.e.,

$$Var[X] = E[(X - E[X])^2].$$

Chama-se desvio-padrão de  $X$ , denota-se por  $\sigma_X$ , a

$$\sigma_X = \sqrt{Var[X]}.$$

$Var[X]$  e  $\sigma_X$  são parâmetros utilizados para medir a dispersão dos valores de  $X$  relativamente ao parâmetro de localização  $E[X]$ .

Observação: Qualquer que seja a natureza da v.a.r.  $X$ , tem-se

$$Var[X] \geq 0.$$

## 6.2 Momentos, variância e desvio-padrão

Propriedades da variância: Seja  $X$  uma v.a.r..

1)  $E[X^2]$  existe sse  $E[X]$  e  $Var[X]$  existem.

[Demonstração] TPC [Ver Lopes & Gonçalves]



## 6.2 Momentos, variância e desvio-padrão

Propriedades da variância: Seja  $X$  uma v.a.r..

I)  $E[X^2]$  existe sse  $E[X]$  e  $Var[X]$  existem.

[Demonstração] TPC [Ver Lopes & Gonçalves]

II)  $Var[X] = 0$  sse  $X$  é uma v.a.r. quase certa, i.e., existe  $a \in \mathbb{R}$  tal que

$$P(X = a) = 1.$$

[Demonstração] TPC [Ver Lopes & Gonçalves]

## 6.2 Momentos, variância e desvio-padrão

Propriedades da variância: Seja  $X$  uma v.a.r..

I)  $E[X^2]$  existe sse  $E[X]$  e  $Var[X]$  existem.

[Demonstração] TPC [Ver Lopes & Gonçalves]

II)  $Var[X] = 0$  sse  $X$  é uma v.a.r. quase certa, i.e., existe  $a \in \mathbb{R}$  tal que

$$P(X = a) = 1.$$

[Demonstração] TPC [Ver Lopes & Gonçalves]

III) Se  $E[X^2]$  existe então  $Var[X] = E[X^2] - (E[X])^2$ .

[Demonstração] É consequência directa da linearidade da esperança matemática.

$$\begin{aligned} Var[X] &= E[(X - E[X])^2] = E[X^2 - 2XE[X] + (E[X])^2] \\ &= E[X^2] - 2E[X]E[X] + (E[X])^2 \\ &= E[X^2] - (E[X])^2 \end{aligned}$$

## 6.2 Momentos, variância e desvio-padrão

### Propriedades da variância (continuação):

IV) Se  $X$  admite momento de ordem 2 então

$$\text{Var}[aX + b] = a^2 \text{Var}[X], \quad \forall a, b \in \mathbb{R}.$$

[Demonstração] Começamos por mostrar que  $\text{Var}[aX + b]$  existe. Para isso, basta mostrar que  $aX + b$  tem momento de 2ª ordem. Usando a linearidade da esperança matemática e o facto de  $E[X^2]$  existir, tem-se que

$$E[(aX + b)^2] = E[a^2X^2 + 2abX + b^2] \leq a^2E[X^2] + 2|ab|E[|X|] + b^2 < +\infty,$$

e concluímos assim que  $\text{Var}[aX + b]$  existe. Vamos agora calculá-la.

$$\begin{aligned} \text{Var}[aX + b] &= E[(aX + b - E[aX + b])^2] = E[(aX + b - aE[X] - b)^2] \\ &= E[(a(X - E[X]))^2] = E[a^2(X - E[X])^2] \\ &= a^2E[(X - E[X])^2] \\ &= a^2\text{Var}[X] \end{aligned}$$

(c.q.d.)

## 6.2 Momentos, variância e desvio-padrão

Exemplos/Exercícios Folha Prática 8: Mostre que

- i) se  $X \sim \text{Poisson}(\lambda)$ , com  $\lambda \in \mathbb{R}^+$ , então  $\text{Var}[X] = \lambda$ ;
- ii) se  $X \sim N(\mu, \sigma^2)$ , com  $\mu \in \mathbb{R}$  e  $\sigma \in \mathbb{R}^+$ , então  $\text{Var}[X] = \sigma^2$ .

Resolução de ii): Como é usual com a lei normal, vamos começar por provar que se  $Y \sim N(0, 1)$  então  $\text{Var}[Y] = 1$  e, de seguida, estender o resultado à lei  $N(\mu, \sigma^2)$ , com quaisquer parâmetros  $\mu$  e  $\sigma^2$ . Para este caso particular, faremos uso da propriedade IV) da variância (ver pág. anterior).

Vamos começar então por provar que  $E[Y^2]$  existe, i.e., que

$$\int_{-\infty}^{+\infty} |x^2|f(x)dx < +\infty,$$

com  $f$  a função densidade de probabilidade da lei  $N(0, 1)$ . Ora:

## 6.2 Momentos, variância e desvio-padrão

Exemplos/Exercícios Folha Prática 8: (continuação - resolução de ii))

$$\begin{aligned}\int_{-\infty}^{+\infty} |x^2| f(x) dx &= 2 \int_0^{+\infty} x^2 \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} x^2 \right\} dx \\ &= \frac{2}{\sqrt{2\pi}} \left\{ \left[ -x \exp \left\{ -\frac{1}{2} x^2 \right\} \right]_0^{+\infty} - \int_0^{+\infty} -\exp \left\{ -\frac{1}{2} x^2 \right\} dx \right\} \\ &= 2 \int_0^{+\infty} \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} x^2 \right\} dx = 2 \times \frac{1}{2} = 1 < +\infty.\end{aligned}$$

Concluimos assim que  $E[Y^2]$  existe e, portanto, que  $Var[Y]$  também existe e, adicionalmente, que é dada por

$$Var[Y] = E[Y^2] - (E[Y])^2 = 1 - 0^2 = 1.$$

Recorde que já foi provado atrás que  $E[Y] = 0$  e que  $E[Y^2] = E[|Y^2|] = 1$ . Resta agora conjugar as propriedades da lei Normal (enunciadas na Secção 4.3) e a propriedade IV) da variância para concluir que, se  $X \sim N(\mu, \sigma^2)$ , então  $Var[X]$  existe e  $Var[X] = \sigma^2$ . (c.q.d.)

## 6.3 Quantis

Para terminar, vamos ainda estudar os *quantis* de uma v.a.r. que, sendo medidas de localização, podem também ser usados para quantificar a sua concentração em certas partes de  $\mathbb{R}$ .

### Definição [Quantil de ordem $p$ ]

Sejam  $X$  uma v.a.r., com função de distribuição  $F$ , e  $p \in ]0, 1[$ . Define-se quantil de ordem  $p$ , denota-se por  $\chi_p$ , a

$$\chi_p = \inf\{c \in \mathbb{R} : F(c) \geq p\}.$$

### Observações:

- 1) Se  $X$  é uma v.a.r. absolutamente contínua e  $F^{-1}(p)$  existe então

$$\chi_p = F^{-1}(p).$$


## 6.3 Quantis

- 2) Em geral, o quantil de ordem  $p$  pode ser visto como o valor real que divide a lei da v.a.r.  $X$  em duas partes: uma de peso máximo igual a  $p$  (a parte inferior a  $\chi_p$ ) e outra de peso máximo igual  $(1 - p)$  (a parte superior a  $\chi_p$ ).

Na situação 1) (da observação anterior) a divisão é exacta, i.e.,

$$P(X < \chi_p) = p \text{ e } P(X > \chi_p) = 1 - p.$$

De facto, neste caso,  $\chi_p$  é o valor que, no gráfico da função densidade de probabilidade, tem à sua esquerda área igual a  $p$  e à sua direita área igual a  $(1 - p)$  (conforme figura abaixo).



## 6.3 Quantis

- 3) Quando  $p = 0.5$ , o quantil é também designado de *mediana*. Grosso modo, a mediana divide a lei da v.a.r. em 2 partes de igual peso: 0.5 cada uma.
- 4) Os quantis  $\chi_{1/4}$ ,  $\chi_{2/4}$  e  $\chi_{3/4}$  são designados de *quartis*, sendo  $\chi_{1/4}$  o 1º *quartil*,  $\chi_{2/4}$  o 2º *quartil* (que coincide com a mediana) e  $\chi_{3/4}$  o 3º *quartil*. Grosso modo, os quartis dividem a lei da v.a.r. em 4 partes de igual peso: 0.25 cada uma.
- 5) Fazendo  $p = i/10$ , com  $i \in \{1, 2, \dots, 9\}$ , obtemos os *decis*. Grosso modo, os decis dividem a lei da v.a.r. em 10 partes de igual peso: 0.1 cada uma.
- 6) Fazendo  $p = i/100$ , com  $i \in \{1, 2, \dots, 99\}$ , obtemos os *percentis*. Grosso modo, os percentis dividem a lei da v.a.r. em 100 partes de igual peso: 0.01 cada uma.